```
Final EDA
 import os
 import numpy as np
 import pandas as pd
 import matplotlib.pyplot as plt
 import seaborn as sns
 %matplotlib inline
 color = sns.color_palette()
 import warnings
 warnings.filterwarnings(action='ignore')
 from sklearn.preprocessing import LabelEncoder
 import statsmodels.api as sm
 from statsmodels.graphics.tsaplots import plot_acf, plot_pacf
 import itertools
 from datetime import date
 import calendar
 train_df = pd.read_excel('2021 빅콘테스트_데이터분석분야_챔피언리그_수산Biz_문제데이터
 add_df = pd.read_excel('2021 빅콘테스트_데이터분석분야_챔피언리그_수산Biz_자율평가데이
 test_df = pd.read_excel('2021 빅콘테스트_데이터분석분야_챔피언리그_수산Biz_평가데이터
1. 데이터 구축
```

```
In [104]:
          # 날짜 변수 추가
          train_df_EDA = train_df.copy()
          train_df_EDA['year'] = train_df_EDA['REG_DATE'].dt.year
          train_df_EDA['month'] = train_df_EDA['REG_DATE'].dt.month
          train_df_EDA['day'] = train_df_EDA['REG_DATE'].dt.day
          train_df_EDA['dayofweek'] = train_df_EDA['REG_DATE'].dt.dayofweek #ㅁ요일 (월 = 0)
          # 품목별 데이터 발췌
          train_df_squid = train_df_EDA.loc[train_df_EDA['P_NAME'] == '오징어']
          train_df_salmon = train_df_EDA.loc[train_df_EDA['P_NAME'] == '연어']
          train_df_shrimp = train_df_EDA.loc[train_df_EDA['P_NAME'] == '흰다리새우']
In [106]:
          train_df_squid.head()
              REG_DATE P_TYPE CTRY_1 CTRY_2 P_PURPOSE CATEGORY_1 CATEGORY_2 P_NAME P_IMI
                                                        연체류 해물
               2015-12-
                        수산물
                                대만
                                                 판매용
                                                                       오징어
          46
                                        대만
                                                                               오징어
                    28
                                                             모듬
                                                        연체류 해물
               2015-12-
          94
                        수산물
                                중국
                                        중국
                                                 판매용
                                                                       오징어
                                                                               오징어
                    28
                                                             모듬
                                                        연체류 해물
               2015-12-
         119
                                페루
                                       페루
                                                판매용
                                                                       오징어
                                                                               오징어
                        수산물
                    28
                                                             모듬
                                                        연체류 해물
               2015-12-
                                        페루
                                                 판매용
                                                                       오징어
                                                                                        냉-
         143
                        수산물
                                페루
                                                                               오징어
                                                             모듬
                    28
               2015-12-
                                                        연체류 해물
                                                                       오징어
```

수산물

28

칠레

칠레

판매용

모듬

160

오징어

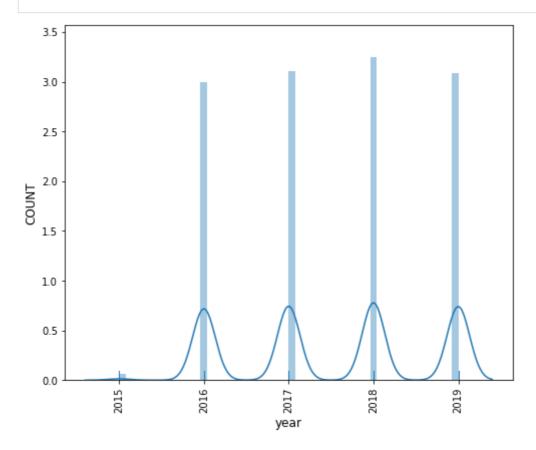
2. EDA (기간별)

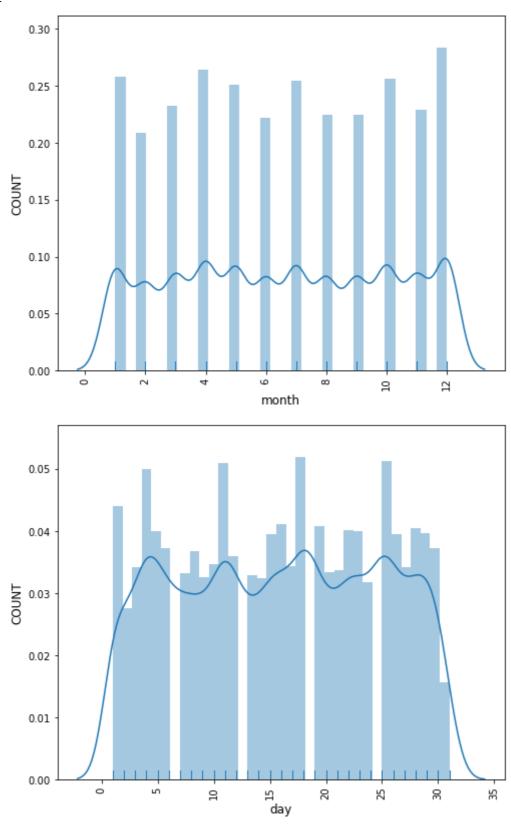
```
# 생산량 흐름 파악
def count_flow(data):
    for i, col in enumerate(['year', 'month', 'day', 'dayofweek']):
       plt.figure(figsize=(8,30))
       ax = plt.subplot(4,1, i+1)
       sns.distplot(x=data[col], hist=True, kde=True, rug=True)
       plt.xticks(rotation='vertical')
       plt.xlabel("%s" % col, fontsize=12)
       plt.ylabel('COUNT', fontsize=12) # 발생 횟수
    return plt.show()
# 가격과 생산량 비교
def price_count(data):
    f, ax = plt.subplots(4,2,figsize=(16,25))
    for i, col in enumerate(['year', 'month', 'day', 'dayofweek']):
       sns.barplot(x=col, y='P_PRICE', data=data, ax=ax[i,0])
       plt.xticks(rotation='vertical')
       sns.countplot(col, data=data, ax=ax[i,1])
       plt.xticks(rotation='vertical')
       plt.xlabel("%s" % col, fontsize=12)
       if i \% 2 == 0:
           plt.ylabel('Mean Price', fontsize=12) # 평균 가격
           plt.ylabel('Sold Count', fontsize=12) # COUNT
```

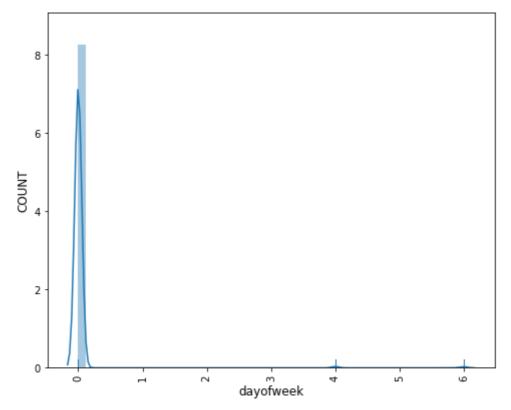
2.1 전체 품목 EDA

In [123]:

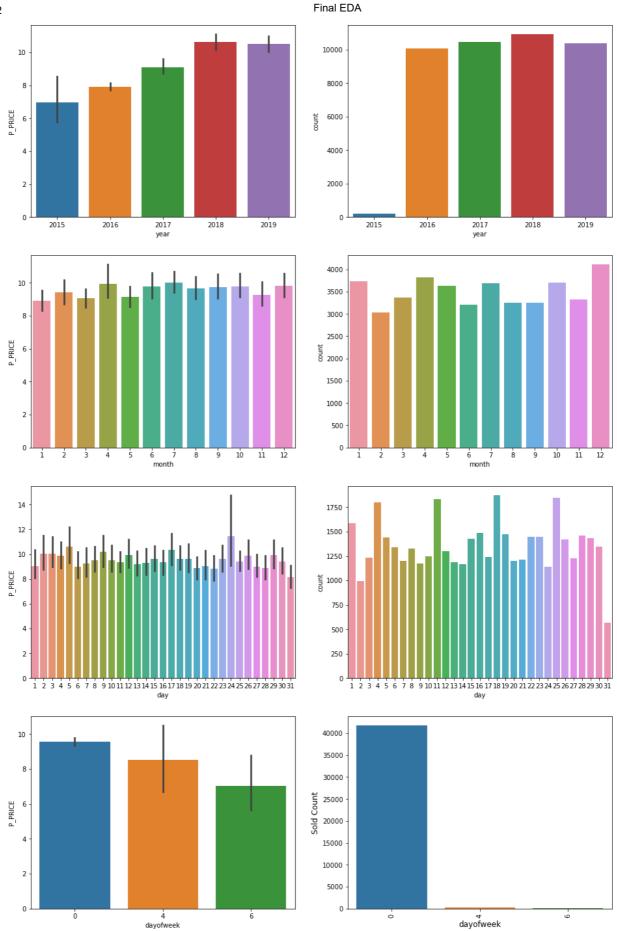
count_flow(train_df_EDA)





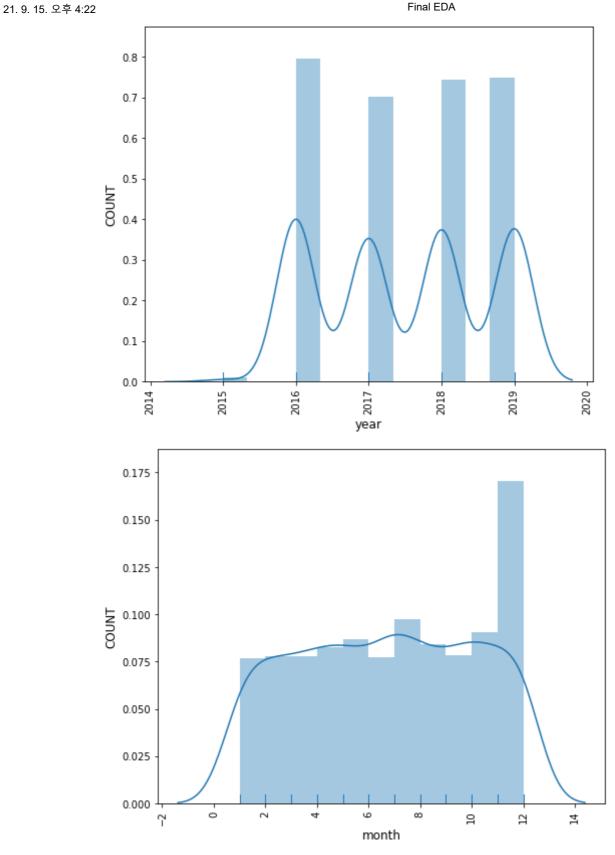


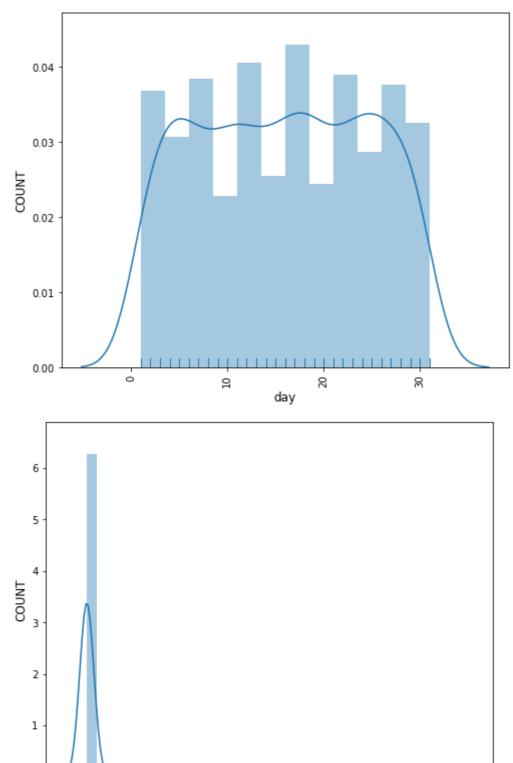
In [124]: price_count(train_df_EDA)



2.2 연어 EDA

In [125]: count_flow(train_df_salmon)



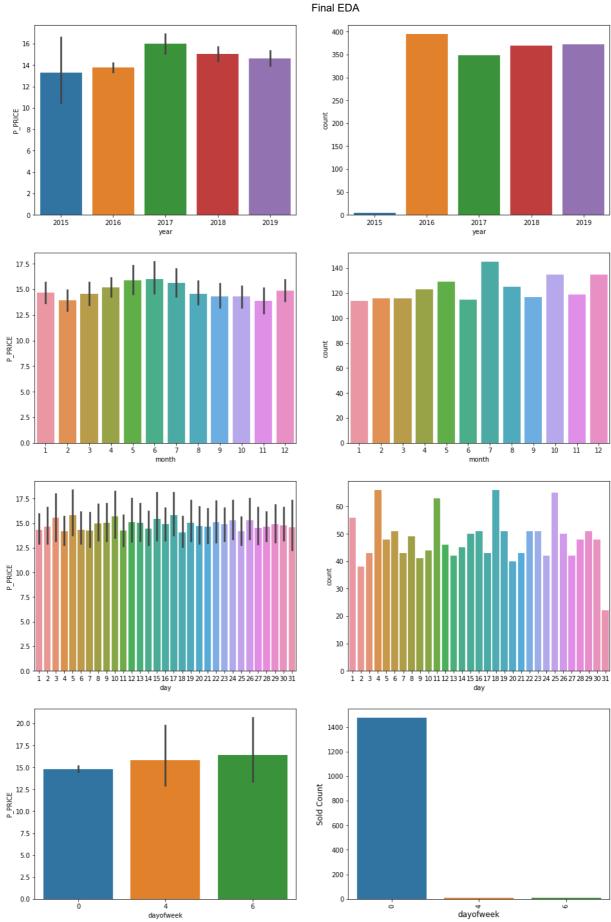


In [126]: price_count(train_df_salmon)

dayofweek

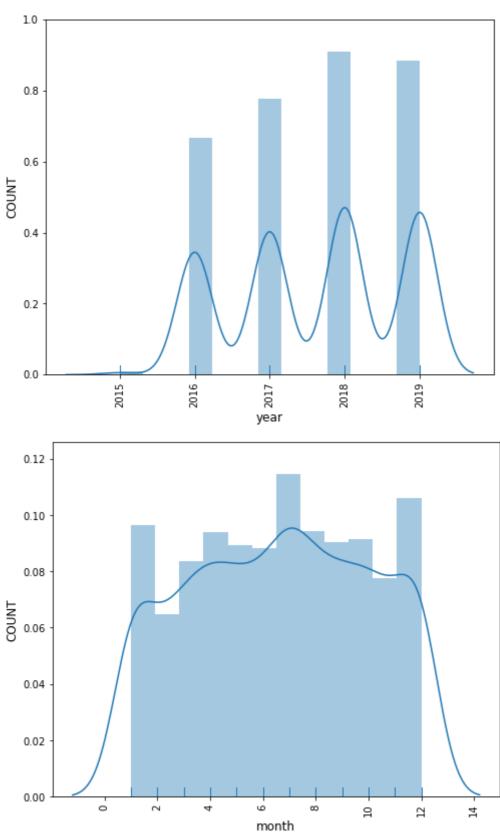
5

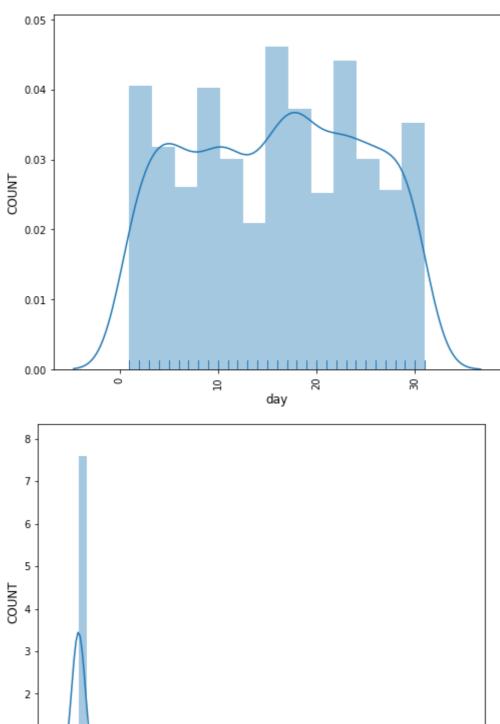
0



2.3 오징어 EDA

In [127]: count_flow(train_df_squid)





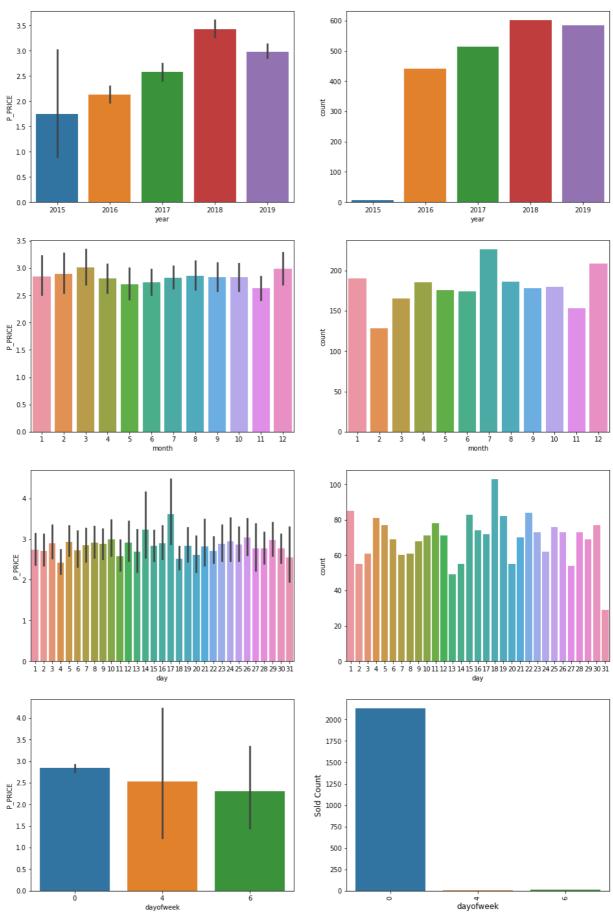
In [128]: price_count(train_df_squid)

dayofweek

5

1

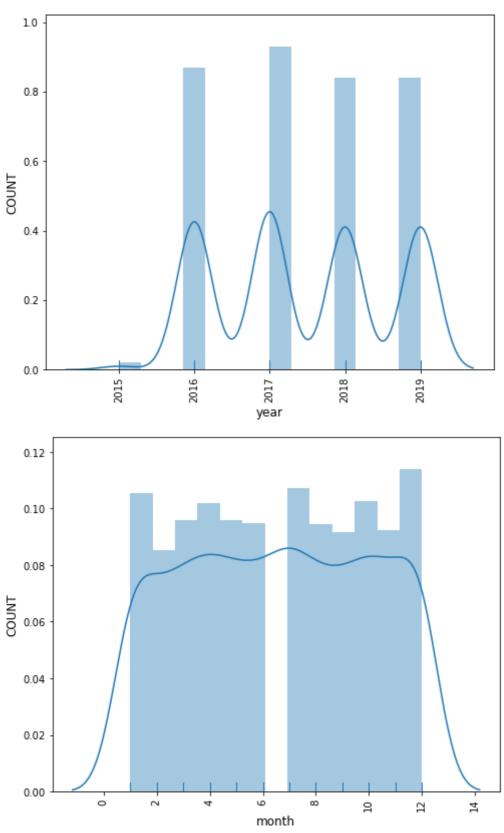
0

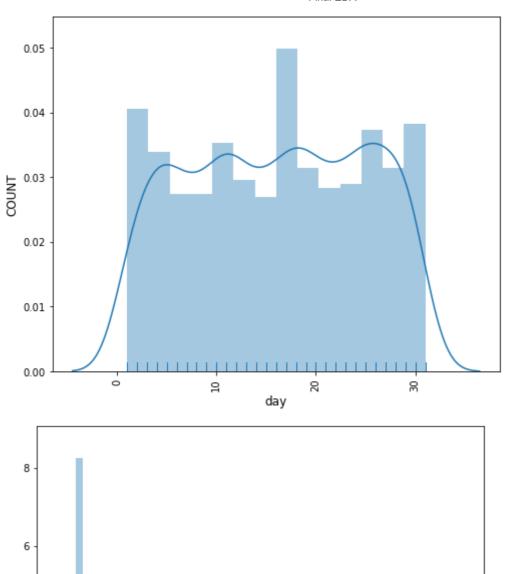


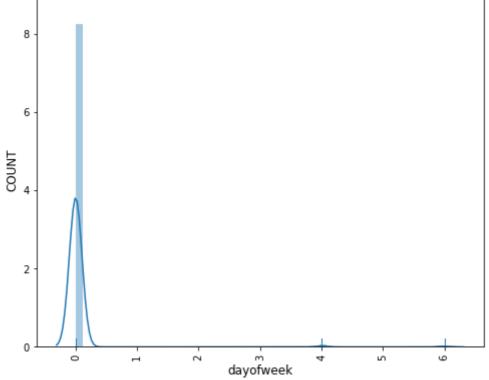
Final EDA

2.4 흰다리새우 EDA

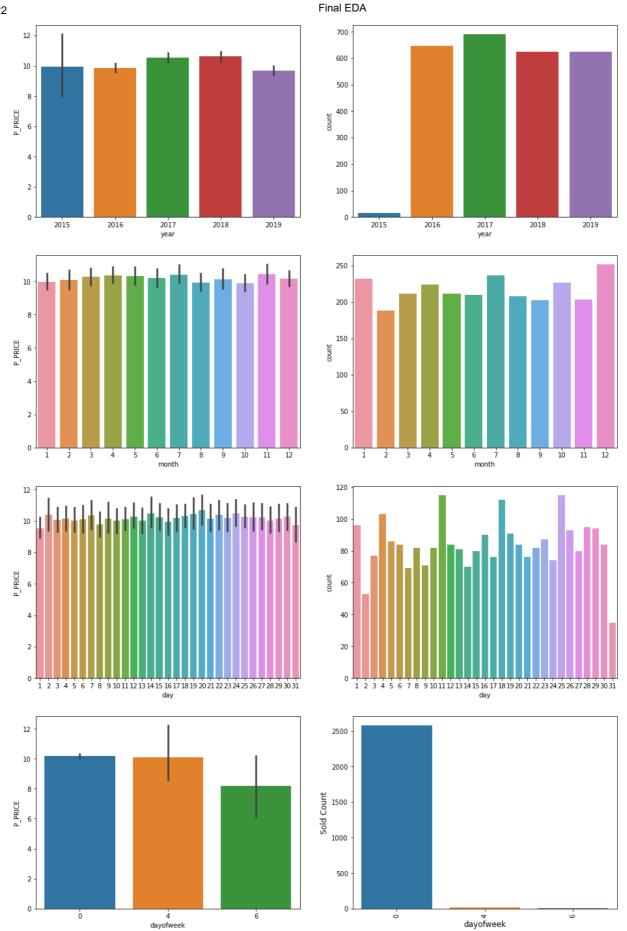
count_flow(train_df_shrimp)







In [130]: price_count(train_df_shrimp)



3. 시계열 모델 사용 조건: 정상성 만족

1. 연어, 오징어, 흰다리새우 데이터에 대해 adfuller 정상성 검정 시행

통계적 검증방법

2. 연어, 오징어, 흰다리새우 데이터에 대해 ACF, PACF Plot 확인

정성적 검증방법

```
# 시계열분석 모델용 Data Preparation
def prepare_df_arima(df, subject):
    # 품목별 저장
    df = train_df.loc[train_df['P_NAME'] == subject]
    arima_df = df.groupby('REG_DATE').mean()
    return arima_df
# 연어, 오징어, 흰다리새우 주차별로 묶기 > 이후 시계열 모델에 사용
groupby_squid = prepare_df_arima(train_df, '오징어')
groupby_salmon = prepare_df_arima(train_df, '엳어')
groupby_shrimp = prepare_df_arima(train_df, '흰다리새우')
groupby_squid.head()
          P PRICE
REG DATE
2015-12-28 1.741647
2016-01-04 1.787152
2016-01-11 1.345855
2016-01-18 1.675178
2016-01-25 2.185579
```

3.1 adfuller

```
In [110]:
         # 정상성 검정 adf
         from statsmodels.tsa.stattools import adfuller
         def ad_test(dataset):
             dftest = adfuller(dataset, autolag = 'AIC')
             print("1. ADF : ",dftest[0])
             print("2. P-Value : ", dftest[1])
              print("3. Num Of Lags : ", dftest[2])
              print("5. Critical Values :")
              for key, val in dftest[4].items():
                 print("\t",key, ": ", val)
In [111]:
         # 연어의 adf
         ad_test(groupby_salmon)
         1. ADF: -3.40231221052143
        2. P-Value: 0.01088030060747892
        3. Num Of Lags: 3
        4. Num Of Observations Used For ADF Regression: 206
```

5. Critical Values:

1%: -3.4624988216864776

```
5%: -2.8756749365852587
                  10%: -2.5743041549627677
In [112]:
          # 오징어의 adf
          ad_test(groupby_squid)
          1. ADF : -2.2821894334544
          2. P-Value: 0.17777658872526164
         3. Num Of Lags: 4
         4. Num Of Observations Used For ADF Regression: 203
         5. Critical Values :
                  1%: -3.462980134086401
                  5%: -2.875885461947131
                  10%: -2.5744164898444515
          # 흰다리새우의 adf
          ad_test(groupby_shrimp)
          1. ADF : -3.8141973729275587
         2. P-Value: 0.002765352088301456
         3. Num Of Lags: 3
         4. Num Of Observations Used For ADF Regression: 206
         5. Critical Values :
                  1%: -3.4624988216864776
                  5%: -2.8756749365852587
                  10%: -2.5743041549627677
```

3.2 acf, pacf plot

```
def acf_pacf(data):
    fig, ax = plt.subplots(1,2, figsize=(10,5))
    fig.suptitle('Raw Data')
    sm.graphics.tsa.plot_acf(data.values.squeeze(), lags=40, ax=ax[0])
    sm.graphics.tsa.plot_pacf(data.values.squeeze(), lags=40, ax=ax[1])

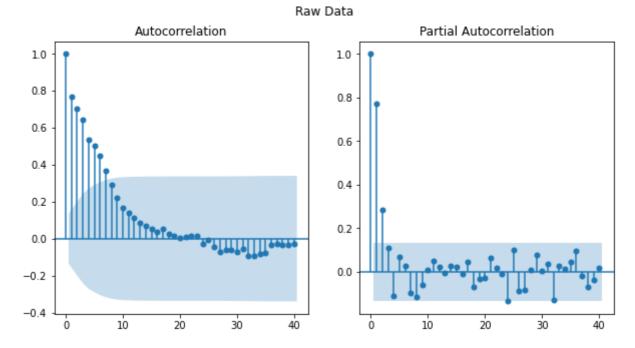
In [115]:

# 차분 진행 후 acf, pacf plot
    def diff_acf_pacf(data):
        diff_data = data.copy()
        diff_data = diff_data.diff()
        diff_data = diff_data.dropna()

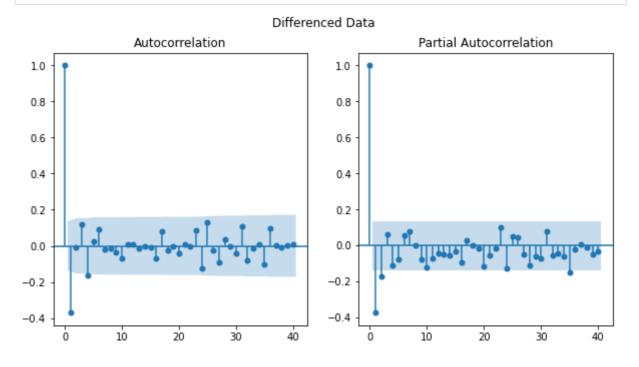
        fig, ax = plt.subplots(1,2, figsize=(10,5))
        fig.suptitle('Differenced Data')
        sm.graphics.tsa.plot_acf(diff_data.values.squeeze(), lags=40, ax=ax[0])
        sm.graphics.tsa.plot_pacf(diff_data.values.squeeze(), lags=40, ax=ax[1]);
```

연어 - acf, pacf

```
In [116]: acf_pacf(groupby_salmon)
```

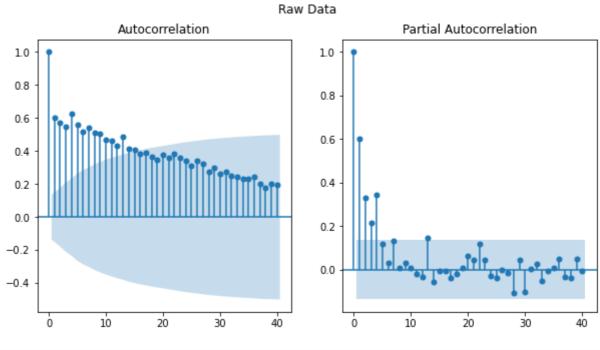


In [117]: diff_acf_pacf(groupby_salmon)

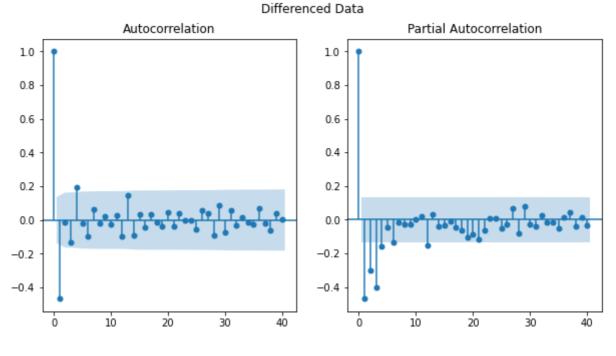


오징어 - acf, pacf

In [118]: acf_pacf(groupby_squid)

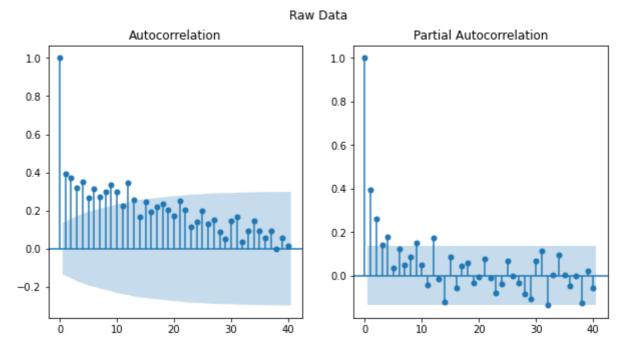


In [119]: diff_acf_pacf(groupby_squid)

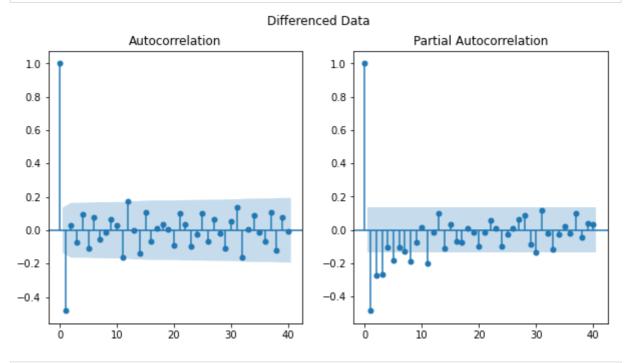


흰다리새우 - acf, pacf

In [120]: acf_pacf(groupby_shrimp)



In [121]: diff_acf_pacf(groupby_shrimp)



In [131]: train_df_salmon

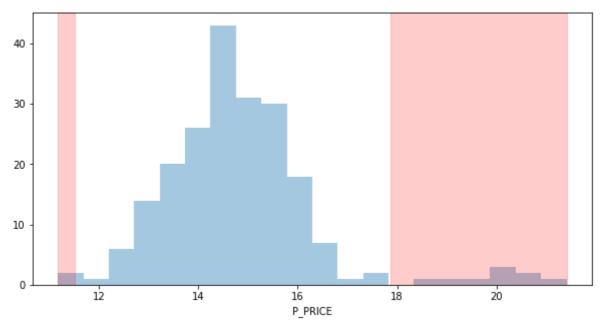
Out[131]:		REG_DATE	P_TYPE	CTRY_1	CTRY_2	P_PURPOSE	CATEGORY_1	CATEGORY_2	P_NAME	P_I
	74	2015-12- 28	수산물	노르웨 이	노르웨 이	판매용	어류	연어	연어	
	129	2015-12- 28	수산물	노르웨 이	노르웨 이	판매용	어류	연어	연어	냉
	168	2015-12- 28	수산물	노르웨 이	노르웨 이	판매용	어류	연어	연어	냉
	174	2015-12- 28	수산물	노르웨 이	노르웨 이	자사제품제 조용	어류	연어	연어	

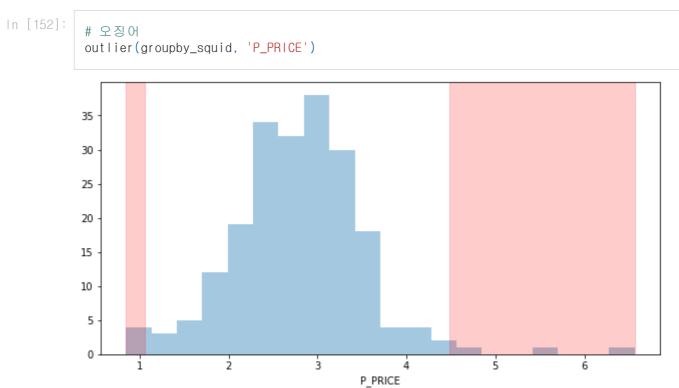
	REG_DATE	P_TYPE	CTRY_1	CTRY_2	P_PURPOSE	CATEGORY_1	CATEGORY_2	P_NAME	P_I
198	2015-12- 28	수산물	노르웨 이	노르웨 이	판매용	어류	연어	연어	
•••									
41994	2019-12- 30	수산물	노르웨 이	노르웨 이	판매용	어류	연어	연어	
41995	2019-12- 30	수산물	노르웨 이	노르웨 이	판매용	어류	연어	연어	냉
42044	2019-12- 30	수산물	노르웨 이	노르웨 이	자사제품제 조용	어류	연어	연어	
42056	2019-12- 30	수산물	노르웨 이	노르웨 이	자사제품제 조용	어류	연어	연어	
42072	2019-12- 30	수산물	노르웨 이	노르웨 이	판매용	어류	연어	연어	

1489 rows × 14 columns

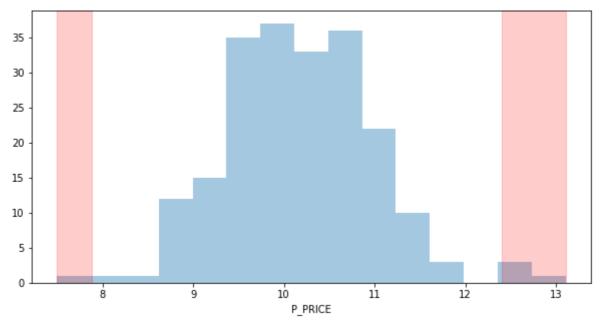
4. 전처리 고려

```
def outlier(data, column):
              q25, q75 = np.quantile(data[column], 0.25), np.quantile(data[column], 0.75)
              # IQR 계산하기
              iqr = q75 - q25
              # outlier cutoff 계산하기
              cut\_off = igr * 1.5
              # lower와 upper bound 값 구하기
              lower, upper = q25 - cut_off, q75 + cut_off
              # boxplot
              plt.figure(figsize=(10,5))
              sns.distplot(data.P_PRICE, kde=False)
              # 이상치 영역 박스 그리기
              plt.axvspan(xmin=lower, xmax=data.P_PRICE.min(), alpha=0.2, color='red')
              plt.axvspan(xmin=upper, xmax=data.P_PRICE.max(), alpha=0.2, color='red')
In [151]:
          # 연어
          outlier(groupby_salmon, 'P_PRICE')
```





```
In [153]: # 흰다리새우
outlier(groupby_shrimp, 'P_PRICE')
```



- 각 품목의 주차별 가격 데이터에서 이상치를 파악 결과, 빨간박스안에 품목별 빨간 박스안에 이상치가 보이긴 하나,
- 소비자물가지수(e나라지표), 어획량 변동에 따라 물가변동이 있을거라 판단
- 따라서 이상치를 제거하지 않기로 결정